

Propuesta de Proyecto: Traductor de Lengua de Señas Colombiana (LSC) mediante Arquitectura YOLO

Tomas Patiño

Introducción a la Visión por Computador

1 Objetivos

1.1 Objetivo General

Desarrollar un sistema de visión artificial basado en aprendizaje profundo para la detección y clasificación en tiempo real del alfabeto estático de la Lengua de Señas Colombiana (LSC), utilizando una arquitectura de detección de objetos de un solo paso (*End-to-End*).

1.2 Objetivos Específicos

- Construir y consolidar un conjunto de datos (*dataset*) propio y representativo mediante la captura fotográfica de 10 voluntarios, garantizando variabilidad en la fisonomía, tonos de piel y fondos.
- Implementar un flujo de pre-procesamiento que incluya la estandarización espacial de las imágenes y la anotación manual de características mediante cajas delimitadoras (*bounding boxes*).
- Entrenar un modelo basado en la arquitectura YOLO, delegando la extracción de características visuales a su red convolucional base (*Backbone*).
- Evaluar el rendimiento del modelo simultáneo de localización y clasificación utilizando la métrica de Precisión Media Promedio (mAP) en entornos no controlados.

2 Investigación del Estado del Arte

La literatura reciente (2023-2025) evidencia una transición desde modelos de clasificación por etapas hacia arquitecturas unificadas para el reconocimiento de lenguaje de señas.

Tyagi et al. (2023) demostraron que la arquitectura YOLO supera a las Redes Neuronales Convolucionales (CNN) tradicionales en la detección del alfabeto de señas (ASL),

logrando un mAP del 96 % en tiempo real, incluso bajo limitaciones de hardware. Por otro lado, investigaciones recientes como la de Madyanto y Wijaya (2025) validan la eficacia de modelos YOLO (específicamente YOLOv8) para la detección de manos en entornos no controlados con fondos complejos, alcanzando precisiones superiores al 90 % frente a variaciones severas de iluminación. Finalmente, diversos estudios comparativos recientes (2025) subrayan que el rendimiento superior al 97 % en estos sistemas depende inherentemente de una estrategia rigurosa de *Data Augmentation* para prevenir el sobreajuste.

3 Aplicación de la Documentación Investigada

La evidencia teórica recolectada fundamenta las decisiones estructurales del presente proyecto:

- **Selección de la Arquitectura:** En respuesta a los hallazgos de Tyagi et al. (2023), se descarta el uso de clasificadores de imágenes estáticos o arquitecturas de múltiples etapas (recorte manual seguido de clasificación). Se adopta YOLO para garantizar un procesamiento *End-to-End*.
- **Diseño del Dataset:** Basado en el estudio de Madyanto y Wijaya (2025) sobre fondos complejos, se justifica la creación de un dataset propio con 10 personas distintas. Esto entrenará al modelo para ignorar el ruido visual del fondo y centrarse estrictamente en la morfología de la seña.
- **Estrategia de Pre-procesamiento:** Siguiendo las directrices metodológicas de 2025 sobre aumento de datos, se aplicarán rotaciones leves y ajustes fotométricos, omitiendo estrictamente el efecto espejo (*horizontal flip*) para preservar el significado lateral de la LSC. Asimismo, se delega la extracción de características al *Backbone* de YOLO, eliminando el uso de filtros manuales de visión clásica.

4 Metodología

El desarrollo del proyecto se ejecutará mediante un enfoque secuencial estructurado en tres capas lógicas principales:

1. Capa de Pre-procesamiento y Aumento de Datos (Input Layer): Inicia con la recolección de las fotografías del alfabeto LSC. Las imágenes estáticas serán consolidadas y sometidas a un proceso de normalización, redimensionándolas a matrices cuadradas de 640×640 píxeles. Previo al entrenamiento, se aplicarán técnicas de **Data Augmentation** (aumento de datos) controladas para robustecer el modelo, incluyendo ajustes fotométricos (brillo y contraste) y variaciones geométricas leves (rotaciones de $\pm 15^\circ$), excluyendo estrictamente la inversión lateral (*horizontal flip*) para no alterar el significado direccional de las señas. Posteriormente, se realizará la anotación espacial manual trazando las *bounding boxes* y asignando la etiqueta correspondiente a cada letra.

2. Capa de Modelado (Shared Layers / Backbone): El conjunto de datos anotado se dividirá en proporciones para entrenamiento, validación y prueba. Las matrices de entrada se procesarán mediante la red convolucional base (*YOLO Backbone*), la cual extraerá los mapas de características jerárquicas sin requerir filtros de extracción de bordes externos, optimizando los núcleos de convolución durante el entrenamiento.

3. Capa de Predicción (Task Layers / YOLO Head): Las características extraídas se canalizarán hacia las cabezas de predicción, las cuales ejecutarán tres tareas simultáneas: la regresión de las coordenadas espaciales de la mano, el cálculo de la probabilidad de presencia del objeto y la clasificación probabilística de la letra. Finalmente, se aplicará el algoritmo de Supresión de No Máximos (NMS) para unificar predicciones redundantes y se evaluará el sistema usando la métrica mAP.

Referencias Bibliográficas

- Tyagi, C., et al. (2023). *American Sign Language Detection using YOLOv5 and YOLOv8*. Preprint / arXiv.
- Madyanto, R. K., & Wijaya, Y. A. (2025). YOLOv8 Algorithm to Improve the Sign Language Letter Detection System Model. *Journal of Artificial Intelligence and Engineering Applications (JAIEA)*, 4(2), 1379–1385.




Figura 1: Diagrama de arquitectura profunda basado en YOLO para la detección y clasificación simultánea de la LSC, estructurado en capas de pre-procesamiento, extracción compartida y tareas de predicción.